

wTech AI 기술문의 자동 답변 시스템

작성부서

인스웨이브 기술지원팀

작성일


2026-06-26

1. 시스템 개요

- 인스웨이브 기술지원팀이 고객 기술문의에 대해 유사 사례 검색(RAG)과 답변 초안 자동 생성을 수행하는 시스템입니다
- 9개 데이터 소스에서 수집한 약 3만 건의 통합 Q&A를 분류·인덱싱하여 답변 근거로 활용합니다
- 실시간 답변 처리(런타임) · 주간 데이터 갱신(배치) · 운영 감시 3개 축으로 구성됩니다

2. 시스템 구성도

외부 채널에서 인입된 문의가 인터페이스 → 답변 처리 파이프라인 → 검색·생성 엔진 → 데이터 계층을 거쳐 처리되며, 별도의 배치·감시 프로세스가 데이터 갱신과 서비스 가용성을 담당합니다.



3. 요청 처리 시퀀스 (런타임 상세)

src/generator/pipeline.js의 process()가 문의 1건을 다음 순서로 처리합니다. 각 단계는 분기·예외에 따라 생략되거나 조기 종료됩니다.

단계	처리 내용	분기 · 예외 처리
①	입력 마스킹 · 캐시 조회	동일 질문 캐시 hit 시 검색·생성을 생략하고 즉시 반환합니다 (첨부 포함 질문은 캐시 제외)
②	서비스 요청 차단 판정	라이선스·데모·파일 제공·계약 등은 RAG-LLM을 거치지 않고 담당자 안내 템플릿만 반환합니다 (BLOCKED)
③	RAG 하이브리드 검색	유사 사례 상위 8건 검색. 신뢰도가 임계값 미만이면 쿼리를 보강해 재검색합니다 (최대 2회)
④	MCP 컨텍스트 보강	WebSquare 컴포넌트 스펙을 주입합니다. MCP 비활성·실패 시 생략하고 진행합니다
⑤	첨부 처리	첨부 이미지 OCR(Tesseract) + 첨부 컨텍스트를 추출합니다. 첨부 없으면 생략합니다
⑥	답변 정책 판정	질문·첨부 기준 위험도 산정 → blocked/human_review 시 사람 검수 안내로 전환합니다
⑦	답변 초안 생성	Codex CLI(codex exec)를 호출합니다. 한국어 비율 미달 등 품질 미흡 시 재시도합니다
⑧	API 존재 검증	응답의 API·이벤트·속성을 로컬 가이드·RAG DB에서 확인합니다. 미확인 시 해당 API 제외 후 최대 1회 재생성합니다
⑨	마스킹 · 저장 · 등록	개인정보 마스킹 → 답변 파일 저장 → 검수 큐 등록 → 답변 캐시 저장

※ 후속 문의(follow-up)는 processFollowUp()이 원문·이전 답변을 함께 입력으로 동일 흐름을 수행합니다.

4. 구성 요소별 역할

구성 요소	역할
데이터 수집 src/collectors	Gmail(IMAP), W-Tech QNA/FAQ(Puppeteer), Confluence 5개 스페이스, API 가이드 (HTML→JSON) 등 9개 소스를 자동 수집합니다
데이터 통합 scripts/merge.js	소스별 원본을 통합 Q&A 포맷으로 변환하고 중복을 제거합니다
자동 분류 src/classifier	정규식 룰 엔진으로 13개 대분류로 자동 분류하고 카테고리별 대표 Q&A 다이제스트를 생성합니다
RAG 검색 src/rag (Python)	multilingual-e5-base 임베딩과 ChromaDB 인덱싱. 벡터·BM25 하이브리드 검색을 수행합니다. 상주 검색 서버로 모델 로딩 비용을 제거합니다
답변 생성 src/generator	분류→검색→보강→정책→생성→검증→마스킹 전 과정을 오케스트레이션합니다. Codex CLI로 초안을 생성한 뒤 API 존재를 검증합니다
REST API src/api (Express)	검색·답변·검수 큐·첨부 다운로드 엔드포인트를 제공합니다 (기본 포트 3000, 답변 생성은 API Key 인증)
운영 감시 scripts/watchdog.sh	서비스 상태를 감시하고, 장애 시 자동 재기동 및 Discord 알림을 발송합니다 (5분 주기)

5. 데이터 소스

9개 소스에서 Q&A 데이터를 자동 크롤링하여 통합합니다. 기존 크롤링 스크립트 26종은 `src/collectors/legacy/`에 참고용으로 보관합니다.

소스	수집 모듈	방식
Gmail 기술문의	gmailCollector.js	IMAP 2-Phase(UID 경량 검색 → 배치 다운로드), X-GM-RAW 병렬 쿼리
W-Tech QNA	wtechCollector.js	QNA 게시판 Puppeteer 크롤링
W-Tech FAQ	wtechFaqCollector.js	FAQ Puppeteer 크롤링
Confluence	confluenceCollector.js	5개 스페이스 (Inside, UXDB, 기술지식DB, PA, W5C)
API 가이드	apiGuideCollector.js	WebSquare API 가이드 HTML → JSON 변환

6. 데이터 흐름

수집된 원본 데이터는 통합·분류·인덱싱을 거쳐 벡터 DB에 적재되며, 답변 생성 시 검색 근거로 활용됩니다.



7. RAG 하이브리드 검색

벡터 검색과 키워드 검색을 가중 결합하여 의미·표현 양쪽을 모두 반영합니다.

처리 순서

- 쿼리 전처리 — 검색 품질 향상을 위한 정규화·보정(preprocessor)
- 벡터 검색 — e5 쿼리 임베딩 후 코사인 유사도 계산 (후보 = 반환 수의 3배)
- BM25 키워드 검색 — BM25Okapi 기반(최초 1회 인덱스 빌드)
- 점수 결합 — 정규화 후 가중 합산 (**벡터 0.6 : BM25 0.4**)
- 상위 8건 선정 — 건당 최대 2,000자로 컨텍스트 구성

주요 사양

임베딩 모델	intfloat/multilingual-e5-base (768차원), 프리픽스 <code>passage: / query:</code>
결합 가중치	벡터(코사인) 0.6 : BM25 0.4
반환 건수	상위 8건
인덱싱 배치	256건 배치 처리, 실패 시 개별 재시도
벡터 DB	ChromaDB — 컬렉션 <code>techassistant_qa</code>

8. 핵심 설계 포인트

- 상주 RAG 검색 서버 — 매 요청마다 임베딩 모델을 새로 로딩하던 약 18초의 비용을 제거하기 위해, 모델·인덱스를 프로세스에 상주시킵니다
 - 표준 라이브러리 HTTP 서버(포트 8765), 127.0.0.1 로컬 바인딩으로 외부에 노출되지 않습니다
 - 서버 장애 시 Node가 searcher.py 서브프로세스 방식으로 자동 폴백하여 무중단에 가깝게 동작합니다
- 답변 캐시 — 동일 질문 재요청 시 검색·생성을 생략하고 즉시 반환합니다 (추가 비용 없음)
 - 디스크 JSON 1개로 보관하여 프로세스 재시작 후에도 유지됩니다. TTL 30일, 최대 500건
 - OCR 결과가 가변적인 첨부 포함 질문은 캐시에서 제외합니다
- 인덱스 동기화 — 상주 서버는 기동 시점의 인덱스를 메모리에 보유하므로, 주간 재인덱싱 후 서버 재시작이 필수입니다 (재시작 공백은 서브프로세스 폴백으로 보완)
- API 존재 검증 루프 — 존재하지 않는 API를 답변에 포함하는 환각을 방지합니다. 미확인 항목 발견 시 해당 API를 제외하고 최대 1회 재생성합니다
- 개인정보 마스킹 — 입력·출력 양단에서 이름·이메일·회사명·프로젝트명을 제거하여 민감정보 노출을 차단합니다

9. 기술 스택

영역	구성
수집·생성·서버	Node.js (18 이상) — Express, Puppeteer, IMAP
RAG 벡터 검색	Python 3.10 — ChromaDB, sentence-transformers(multilingual-e5-base), rank-bm25, torch
LLM	Codex CLI (codex exec) — 답변 초안 생성 백엔드
OCR	Tesseract — 첨부 이미지 텍스트 추출
벡터 DB	ChromaDB — 컬렉션 techassistant_qa (768차원)

10. 운영

구분	내용
주간 배치	주간 단위로 수집 → 통합 → 분류 → 재인덱싱을 수행하고, 완료 후 상주 RAG 서버를 재시작하여 신규 데이터를 검색에 반영합니다
상시 감시	5분 주기로 서비스 상태를 점검하여 장애 시 자동 재기동 및 Discord 알림을 발송하고, 오류 로그의 LLM 실패-rate limit 신호를 감시합니다
답변 캐시	동일 질문 재요청 시 검색·생성 단계를 생략하고 즉시 반환합니다 (보관 30일, 첨부 포함 질문은 제외)
서버 구성	API 서버(:3000)와 상주 RAG 서버(:8765)가 각각 상주하며, cron으로 주간 배치·5분 감시를 수행합니다